

Diagnóstico Metodológico en Aprendizaje Automático: del Espejismo de la *Accuracy* a la Predicción de Depresión en Adolescentes

Kevin Argueta

Postgrado de Inteligencia Artificial, Universidad Galileo, Guatemala

26003999@galileo.edu

Mayo 2026

ABSTRACT

El presente trabajo aplica técnicas de aprendizaje automático supervisado sobre un dataset de 1 200 adolescentes para clasificar indicadores de salud mental a partir de hábitos digitales, de sueño y bienestar psicológico. El aporte central es **metodológico**: un modelo inicial alcanzó una *accuracy* aparente del 60 %, pero el análisis con métricas para datos desbalanceados reveló una *balanced accuracy* de 0.33 (equivalente al azar). Mediante un proceso de diagnóstico guiado por el análisis exploratorio (EDA) —validación independiente, SMOTE, `RandomizedSearchCV`, detección de anomalías, selección de variables y reevaluación del *target*— se identificó que el desempeño estaba limitado por la **definición del target**, no por el modelo. Al sustituir el target compuesto por uno real del dataset (`depression_label`) y usar las variables psicológicas como predictores legítimos, el modelo final alcanzó una *balanced accuracy* del 100 %. Las variables más predictivas fueron horas de sueño, estrés, ansiedad y uso de redes sociales. El trabajo demuestra que el valor proviene del proceso de diagnóstico de datos más que de la potencia del algoritmo.

Palabras clave: salud mental adolescentes, datos desbalanceados, *balanced accuracy*, definición de target, SMOTE, predicción de depresión.

1. INTRODUCCIÓN

El uso intensivo de redes sociales en adolescentes se ha convertido en uno de los fenómenos más estudiados en salud pública durante la última década. Investigaciones recientes señalan correlaciones significativas entre el tiempo de pantalla, la calidad del sueño, el rendimiento académico y el bienestar psicológico en jóvenes de 13 a 19 años [1, 2].

La interacción social es un determinante clave del desarrollo emocional en la adolescencia. Comprender qué factores predicen que un joven presente un nivel *bajo*, *medio* o *alto* de interacción social puede orientar intervenciones preventivas en contextos educativos y clínicos.

1.1. Planteamiento del problema

Dado un conjunto de variables observables (horas en redes sociales, plataforma preferida, horas de sueño, tiempo de pantalla antes de dormir, rendimiento académico, actividad física, nivel de estrés, ansiedad y adicción digital), ¿es posible predecir el nivel de interacción social de un adolescente mediante técnicas de aprendizaje automático?

1.2. Objetivos

- Explorar y caracterizar el dataset de salud mental adolescente.
- Identificar variables con mayor poder predictivo.
- Entrenar y evaluar un modelo de clasificación supervisada.
- Documentar hallazgos y proponer mejoras me-

todológicas.

2. METODOLOGÍA

2.1. Dataset

Se utilizó el dataset público *Teen Mental Health & Social Media* [3], disponible en Kaggle. Contiene **1 200 registros** y **13 columnas**. La variable objetivo es `social_interaction_level` (categórica: *low*, *medium*, *high*). No se encontraron valores nulos ni registros duplicados.

Cuadro 1: Variables del dataset

Variable	Descripción
age	Edad (13–19 años)
gender	Género (male / female)
daily_social_media_hours	Horas diarias en redes
platform_usage	Plataforma principal
sleep_hours	Horas de sueño
screen_time_before_sleep	Pantalla antes de dormir (h)
academic_performance	Promedio académico (2.0–4.0)
physical_activity	Actividad física (h)
stress_level	Nivel de estrés (1–10)
anxiety_level	Nivel de ansiedad (1–10)
addiction_level	Nivel de adicción (1–10)
depression_label	Etiqueta de depresión (0/1)
<code>social_interaction_level</code>	Variable objetivo

2.2. Análisis Exploratorio de Datos

Se realizaron cuatro análisis visuales principales:

1. Distribución de la variable objetivo (barras y pastel).
2. Histogramas de variables numéricas.
3. Mapa de correlación entre variables numéricas.
4. Tabla cruzada entre variables categóricas y el target.




Figura 1: Distribución del nivel de interacción social. Las tres clases están balanceadas: medium (34.7 %), low (34.6 %) y high (30.8 %).




Figura 2: Mapa de correlación de Pearson. Se observan correlaciones moderadas entre `stress_level`, `anxiety_level` y `addiction_level`.




Figura 3: Distribución de las variables numéricas. La mayoría presenta distribuciones aproximadamente unimodales.

2.3. Preprocesamiento

- **Valores nulos:** ninguno encontrado.
- **Duplicados:** ninguno.
- **Codificación:** variables categóricas transformadas con *Label Encoding*.
- **División:** 80 % entrenamiento (960 muestras) / 20 % prueba (240 muestras), estratificada por clase.

2.4. Modelos propuestos

Se propuso la evaluación de tres modelos de clasificación:

1. **Random Forest** [4] — método de ensamble basado en árboles de decisión con bagging; robusto ante overfitting.
2. **Regresión Logística Multinomial** — modelo lineal de referencia (*baseline*); interpretable y eficiente.
3. **Support Vector Machine (SVM)** con kernel RBF — efectivo en espacios de alta dimensión y fronteras no lineales.

En la implementación actual se entrenó y evaluó el modelo Random Forest como prueba de concepto principal, utilizando la librería scikit-learn [5].

2.5. Métricas de evaluación

- **Accuracy** — proporción de predicciones correctas.
- **Precision** (macro) — exactitud por clase.
- **Recall** (macro) — sensibilidad por clase.
- **F1-score** (macro) — media armónica de precisión y recall.
- **Matriz de confusión** — visualización de errores.

3. RESULTADOS

3.1. Hallazgos del EDA

- Dataset **bien balanceado**: 34.7 % medium, 34.6 % low, 30.8 % high.
- Edad promedio: 15.9 años (rango 13–19).
- Promedio de **4.5 horas diarias** en redes sociales y **6.4 horas** de sueño.
- `stress_level`, `anxiety_level` y `addiction_level` correlacionan moderadamente entre sí ($r \approx 0,3-0,5$), pero muestran correlación baja con la variable objetivo.
- Solo el **2.6 %** de los adolescentes tiene etiqueta de depresión positiva, indicando alta asimetría en esa variable.

3.2. Comparativa de modelos

Se entrenaron y compararon cinco algoritmos sobre el target inicial `mental_health_risk`, con validación cruzada de 5 pliegues (Tabla 2). La **Red Neuronal (MLP)** obtuvo la mayor *accuracy* (60 %), seguida de Random Forest (58.3 %).

Cuadro 2: Comparativa de modelos (target inicial, conjunto de prueba)

Modelo	CV Acc.	Test Acc.
Red Neuronal (MLP)	0.607	0.600
Random Forest	0.602	0.583
Gradient Boosting	0.551	0.567
XGBoost	0.539	0.533
SVM (RBF)	0.346	0.413
Baseline aleatorio (3 clases): $\approx 33,3\%$		

Sin embargo, como se discute en *Mejoras Metodológicas*, este 60 % es engañoso: todos los modelos se apoyan en la clase mayoritaria. La verdadera comparativa de *enfoques* —no de algoritmos— se resume en la Tabla 5, donde el criterio es la *balanced accuracy*.




Figura 4: Matriz de confusión del modelo base. El modelo concentra sus predicciones en la clase mayoritaria *Medio*.

3.3. Importancia de variables




Figura 5: Importancia de variables del modelo base. Las variables derivadas por *feature engineering* encabezan el ranking.

El ranking de las tres variables más importantes fue:

1. `social_media_sleep_ratio`
2. `academic_performance`
3. `activity_sleep_ratio`

No obstante, dado el bajo desempeño real del modelo base (ver *Mejoras Metodológicas*), estas importancias deben interpretarse con cautela: reflejan cómo el modelo intenta separar un target débilmente determinado, no relaciones causales robustas.

4. DISCUSIÓN

Una exactitud del 34.17 % es marginalmente superior al azar (33.3 % para tres clases equiprobables), lo que indica que el modelo captura *alguna* señal predictiva pero de forma insuficiente para aplicación real. Entre las causas identificadas:

- **Variable objetivo débilmente determinada:** el nivel de interacción social depende de factores no capturados en el dataset (personalidad, contexto familiar, acceso a internet).
- **Correlaciones bajas:** el mapa de calor evidenció que ninguna variable individual tiene correlación fuerte con `social_interaction_level`.
- **Ausencia de normalización:** aunque Random Forest es robusto a escalas distintas, los mode-

los alternativos propuestos (Regresión Logística, SVM) sí la requieren.

5. MEJORAS METODOLÓGICAS

A partir de las sugerencias recibidas durante la exposición del proyecto, y siguiendo un flujo de referencia de manejo de datos [7], se aplicaron seis mejoras metodológicas orientadas a obtener una evaluación más honesta y a intentar elevar el desempeño en las clases minoritarias. Cada técnica se evaluó de forma cuantitativa para verificar, de manera científica, su efecto real sobre el modelo.

5.1. Conjunto de validación independiente

La partición original (80/20) se sustituyó por una partición **estratificada en tres conjuntos**: entrenamiento (60 %), validación (20 %) y prueba (20 %). El conjunto de validación permite ajustar hiperparámetros sin contaminar el conjunto de prueba, que se reserva para una única medición final. Así se evita el sobreajuste optimista que aparece cuando el mismo conjunto se usa para seleccionar y reportar.

5.2. Técnicas de muestreo (SMOTE)

La variable objetivo presenta un fuerte desbalance (*Medio*: 60.9 %, *Bajo*: 21.2 %, *Alto*: 17.9 %). Se aplicó **SMOTE** (*Synthetic Minority Over-sampling Technique*) [6] para sintetizar ejemplos de las clases minoritarias. Crucialmente, el sobre-muestreo se encapsuló dentro de un **Pipeline** de **imbalanced-learn**, de modo que SMOTE se aplica *solo a los pliegues de entrenamiento* dentro de la validación cruzada y nunca sobre los datos de validación, evitando fuga de información (*data leakage*).

5.3. Búsqueda de hiperparámetros

Se empleó **RandomizedSearchCV** (40 combinaciones, **StratifiedKFold** de 5 pliegues) sobre el número de árboles, profundidad máxima, mínimo de muestras por hoja, número de características por división y vecinos de SMOTE. La métrica de selección fue **F1-macro**, no *accuracy*. Los mejores hiperparámetros fueron: **n_estimators=200**, **max_depth=None**,

min_samples_leaf=2, **max_features=0.5** y **SMOTE** con **k_neighbors=3**.

5.4. Métricas para datos desbalanceados

Con clases desbalanceadas la *accuracy* es engañosa: un modelo que predice siempre la clase mayoritaria *Medio* obtiene ≈ 60 % sin aprender nada. Por ello se adoptaron métricas que ponderan las clases por igual:

- **Balanced accuracy** — promedio del *recall* por clase; el azar equivale a $1/3$.
- **F1-macro** — media no ponderada del F1 de cada clase, penalizando el abandono de las clases minoritarias.

5.5. Detección de anomalías

Antes de modelar se verificó la calidad de los datos con dos técnicas complementarias. El análisis de **Z-score** ($|z| > 3$) no detectó **ningún valor atípico**, y el **Isolation Forest** (*contamination=2* %) marcó apenas 24 observaciones sin estructura clara. Esto confirma que el dataset es limpio y que sus distribuciones casi uniformes no presentan anomalías relevantes, por lo que no fue necesario filtrar registros.

5.6. Selección de variables (ANOVA y RFE)

Se aplicó un análisis de varianza (**ANOVA F-test**) para cuantificar el poder discriminante de cada variable. Únicamente **depression_label** mostró un valor alto ($F = 16,5$); el resto se ubicó entre 1 y 2, evidenciando una señal débil generalizada. A continuación se empleó **Recursive Feature Elimination (RFE)** con un *Random Forest* como estimador base, seleccionando las 6 variables más relevantes de las 13 disponibles. Reentrenar el pipeline optimizado únicamente con estas variables produjo una **mejora modesta pero medible** en las métricas justas (Tabla 3).

Cuadro 3: Efecto de la selección de variables (RFE)

Configuración	Acc.	Bal. Acc.	F1-macro
13 variables (todas)	0.429	0.280	0.273
6 variables (RFE)	0.421	0.292	0.292

Eliminar variables ruidosas elevó el F1-macro de

0.273 a 0.292 y la *balanced accuracy* de 0.280 a 0.292, demostrando de forma cuantitativa que un subconjunto más compacto generaliza mejor. No obstante, la magnitud de la mejora reafirma que el techo del problema está limitado por la información disponible, no por el número de variables.

5.7. Resultados de las mejoras

Cuadro 4: Modelo base vs. modelo optimizado (conjunto de prueba)

Modelo	Acc.	Bal. Acc.	F1-macro
Base (MLP)	0.600	0.333	0.26
SMOTE + RF (optimizado)	0.429	0.280	0.27

Azar (3 clases): Acc/Bal. Acc. $\approx$ 0,333

El hallazgo es revelador: aunque el modelo base alcanza 60 % de *accuracy*, su *balanced accuracy* de 0.333 demuestra que **solo predice la clase mayoritaria** (recall 0.98 en *Medio*, ≈ 0 en *Bajo* y *Alto*). Al balancear con SMOTE y optimizar para F1-macro, el modelo distribuye sus predicciones entre las tres clases, pero el F1-macro apenas mejora ($0.26 \rightarrow 0.27$) y la *accuracy* cae al perder el “atajo” de la clase mayoritaria.

Esto confirma que **las variables disponibles no contienen señal suficiente** para discriminar el nivel de riesgo: ni el balanceo ni la optimización de hiperparámetros pueden crear información predictiva inexistente. El valor metodológico de las mejoras no es elevar un número, sino **exponer la verdadera dificultad del problema**, antes oculta tras una métrica inflada.

6. REEVALUACIÓN DEL TARGET Y MODELO FINAL

6.1. Diagnóstico: el target estaba mal definido

El EDA mostró que el target `mental_health_risk` se había construido como el *promedio* de **stress**, **anxiety** y **addiction**. Promediar tres variables concentra los valores en el centro, generando un 60.9 % de casos *Medio* por efecto estadístico, no por los datos. Al redefinir el target con **percentiles (33/33/33)**, la *balanced accuracy* subió de 0.31 a 0.39, superando por primera vez el azar y

confirmando que el sesgo era un artefacto de la definición del target.

Un **experimento de control** (mismo target, agregando las variables que lo componen como predictores) alcanzó 0.90 de *balanced accuracy*. Aunque es *data leakage* y no constituye un modelo usable, prueba de forma concluyente que la señal predictiva vive en **stress**, **anxiety** y **sleep**, no en el target promediado.

6.2. Modelo final: predicción de depresión

La evidencia anterior indicó el camino correcto: **abandonar el target inventado** y usar un target **real y medido** del dataset, `depression_label`. Con este cambio, **stress**, **anxiety**, **sleep** y el uso de redes pasan a ser **predictores legítimos** (el target ya no se deriva de ellos). Usando el mismo pipeline optimizado (SMOTE + Random Forest), el modelo final alcanzó métricas perfectas en el conjunto de prueba, detectando los 6 casos de depresión sin falsos positivos. Las variables más importantes fueron horas de sueño (0.33), estrés (0.29), ansiedad (0.19) y horas en redes sociales (0.15).

Cuadro 5: Evolución del desempeño a lo largo del análisis

Etapas	Target	Bal. Acc.	F1
Inicial (MLP)	promedio	0.33	0.26
Optimizado (SMOTE+RF)	promedio	0.28	0.27
Target percentiles	percentiles	0.39	0.39
Final	depression	1.00	1.00

Nota de honestidad científica: el dataset es sintético y la regla de generación de la depresión (estrés y ansiedad altos, sueño bajo, redes altas) es aprendible casi perfectamente. En datos reales se esperaría menor exactitud; el aporte del trabajo es la **metodología de diagnóstico**, no la cifra final.

7. CONCLUSIONES

1. El dataset es de alta calidad estructural (sin nulos, sin duplicados y sin anomalías detectables por Z-score o *Isolation Forest*), lo que descarta problemas de limpieza como causa del bajo desempeño.

2. La *accuracy* del 60 % del modelo base es un **espejismo**: su *balanced accuracy* de 0.333 (equivalente al azar) demuestra que el modelo **no discrimina**, sino que predice casi siempre la clase mayoritaria *Medio*. Esto subraya por qué, en datos desbalanceados, la *accuracy* no debe usarse como métrica única.
 3. El sesgo hacia *Medio* tiene una **causa raíz en la construcción del target**: al definirse como el *promedio* de tres variables (estrés, ansiedad, adicción), los valores se concentran en el rango central por efecto estadístico del promediado, produciendo un 60.9 % de casos *Medio* independientemente de los datos.
 4. Las mejoras metodológicas (validación independiente, SMOTE, `RandomizedSearchCV` y selección de variables) no elevaron el rendimiento, sino que **revelaron la verdadera dificultad del problema**. La selección de variables con RFE aportó la única mejora medible ($F1\text{-macro } 0.273 \rightarrow 0.292$), confirmando que un subconjunto compacto generaliza algo mejor, pero sin superar el techo impuesto por la falta de señal predictiva en las variables.
 5. Actuando sobre ese diagnóstico, se **redefinió el target**: en lugar del promedio inventado se usó `depression_label` (variable real del dataset), lo que convierte a estrés, ansiedad, sueño y redes en predictores legítimos. El **modelo final** alcanzó una *balanced accuracy* del 100 %, confirmando que la mejora provino del **análisis de los datos**, no de un algoritmo más potente.
 6. Como trabajo futuro se propone: (a) validar la metodología en un dataset **real** (el actual es sintético, con reglas aprendibles), (b) incorporar variables con mayor poder predictivo (contexto familiar, personalidad), y (c) recolectar más casos reales de las clases minoritarias en lugar de sintetizarlas.
- [2] Keles, B., McCrae, N., & Grealish, A. (2020). *A systematic review: the influence of social media on depression, anxiety and psychological distress in adolescents*. International Journal of Adolescence and Youth, 25(1), 79–93.
 - [3] AlgoZee. (2024). *Teen Mental Health & Social Media Dataset* [Dataset]. Kaggle. <https://www.kaggle.com/datasets/algozee/teenager-menthal-healy>
 - [4] Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5–32.
 - [5] Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
 - [6] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. Journal of Artificial Intelligence Research, 16, 321–357.
 - [7] Universidad Galileo (2024). *Data Demo 03: Flujo de manejo de datos y modelado supervisado* [Material de curso]. Manejo de Datos para la IA.

REFERENCIAS

- [1] Twenge, J. M., & Campbell, W. K. (2019). *Media Use Is Linked to Lower Psychological Well-Being: Evidence from Three Datasets*. Psychiatric Quarterly, 90(2), 311–331.